

Interpretabilni modeli dubokog učenja za otkrivanje dinamike sustava

Josip Dujmenović

*Fizički odsjek, Prirodoslovno-matematički fakultet, Sveučilište u Zagrebu, Bijenička
cesta 32, 10000 Zagreb, Hrvatska*

Mentor: prof. dr. sc. Davor Horvatić

*Fizički odsjek, Prirodoslovno-matematički fakultet, Sveučilište u Zagrebu, Zavod za
teorijsku fiziku čestica i polja, Bijenička cesta 32, 10000 Zagreb, Hrvatska*

19. siječnja 2025.

Sažetak

Ovaj seminar se bavi prognozom multivarijatnih vremenskih nizova u fizici i općenito, s naglaskom na interpretabilne modele dubokog učenja. Koristi se model DCIts (Deep Convolutional Interpreter for Time Series), arhitektura koja uz predikciju istovremeno uči interpretabilne koeficijente međusobnih utjecaja između vremenskih nizova i vremenskih pomaka (lagova). U radu se daje pregled motivacije i ograničenja klasičnih pristupa te se detaljno opisuje struktura DCIts-a i način na koji se iz modela izvlači interpretacija. Model je evaluiran na sintetičkim skupovima podataka s poznatom dinamikom te je dodatno analizirana dobra robusnost na šum i nedostajuća mjerenja, ali manja robusnost na promjenu dinamike u neviđenim podacima. Konačno, DCIts je uspješno primijenjen na simulirane fizikalne podatke dobivene iz Izhikevichevog modela neuronske mreže.

1 Uvod

Cilj seminara je primijeniti interpretabilni model dubokog učenja za prognozu fizikalnog sustava koji je opisan vremenskim nizovima. Modeli dubokog učenja imaju veliku točnost, ali zbog velikog broja parametara teško ih je interpretirati, što znači da ne možemo naučiti puno o sustavu na koji ih primjenjujemo. U tu svrhu koristimo model Duboki konvolucijski interpretator vremenskih nizova (engl. DCIts - Deep Convolutional Interpreter for Time Series)^[1].

1.1 Vremenski nizovi

Vremenski niz ili vremenska serija je diskretni skup podataka neke veličine u različitim vremenskim trenucima, pri čemu su ti vremenski trenuci najčešće jednako razmaknuti:

$$(X_{t_1}, X_{t_2}, \dots, X_{t_N}). \quad (1)$$

Ovdje su X_t vrijednosti fizikalne veličine u različitim vremenskim trenucima t , npr. vrijednost temperature za svaki sat u danu. Ovakav vremenski niz se još naziva i univarijatni vremenski niz.

Multivarijatni vremenski nizovi su više različitih vremenskih nizova koji mogu biti međusobno povezani na različite načine:

$$\begin{aligned} &(X_{t_1}, X_{t_2}, \dots, X_{t_N}) \\ &(Y_{t_1}, Y_{t_2}, \dots, Y_{t_N}) \\ &(Z_{t_1}, Z_{t_2}, \dots, Z_{t_N}) \end{aligned} \quad (2)$$

Ovdje su izmjerene vrijednosti veličina X_t , Y_t , Z_t u istim trenucima t , npr. vrijednosti temperature T_t , volumena V_t i tlaka p_t u istom trenutku t . Vremenski nizovi su obilježene trendom i sezonalnošću. Trend je dugoročno povećanje ili smanjenje vrijednosti kroz vrijeme, dok je sezonalnost periodičko ponavljanje uzorka.

1.2 Linearni modeli vremenskih nizova^[2]

Treba napomenuti nekoliko bitnih razlika između regresijskih metoda i modeliranja vremenskih nizova. Regresijska analiza je statistička metoda koja se koristi za ispitivanje odnosa između neke zavisne varijable y_i i jedne ili više nezavisnih varijabli (prediktora) x_i . U klasičnoj regresiji promatramo parove (x_i, y_i) i tražimo odnos

$$y_i = f(x_i) + \varepsilon_i, \quad (3)$$

gdje je $f(x_i)$ funkcija koja predviđa vrijednosti y_i preko x_i , a ε_i neizbježna greška modela. Pritom se obično pretpostavlja da su opažanja međusobno nezavisna i da su pogreške nekorelirane. Takav opis dobro odgovara situacijama gdje je svako mjerenje zaseban uzorak.

Kod vremenskih nizova redosljed opažanja je bitan, jer sustav ima dinamiku, buduće stanje ovisi o prošlim stanjima. Zbog toga prognozu tipično zapisujemo kao:

$$x_{t+1} = f(x_t, x_{t-1}, \dots, x_{t-L+1}) + \varepsilon_{t+1}, \quad (4)$$

odnosno vrijednost veličine u sljedećem trenutku x_{t+1} ovisi o vrijednostima te veličine u L prošlih trenutaka (lagova), a ε_{t+1} je greška modela.

Ako se na vremenske nizove primijeni obična linearna regresija bez uvažavanja vremenske zavisnosti, može se dobiti razumno predviđanje trenda, ali standardne pogreške i statistička pouzdanost koeficijenata mogu biti pogrešno procijenjeni zbog korelacije u nizovima.

Zbog toga se za vremenske nizove razvijaju posebni modeli. U najjednostavnijem slučaju to su linearni modeli kao što su autoregresivni modeli $AR(p)$, modeli pomičnog prosjeka $MA(q)$, kombinirani $ARMA/ARIMA$ modeli te njihovi multivarijatni ekvivalenti (npr. VAR modeli). Oni eksplicitno uzimaju u obzir prošle vrijednosti i često mogu dobro opisati linearnu dinamiku uz trend i sezonalnost.

1.3 Problem interpretabilnosti dubokih modela

U većini fizikalnih situacija i eksperimenata jednostavni modeli su vrlo korisni jer se lako interpretiraju i daju nam nova saznanja o sustavu koji promatramo pa zato često pokušavamo linearizirati komplicirane sustave. Međutim, predikcija i točnost tako jednostavnih modela nije uvijek zadovoljavajuća i tu u priču ulaze modeli dubokog učenja. Modeli dubokog učenja, općenito i u vremenskim nizovima, postižu visoku točnost i imaju veliku moć predikcije^[3], ali njihova složena priroda otežava interpretaciju predikcija, što znači da iz njih ne možemo lako naučiti nove stvari o fizikalnom sustavu.

Ovaj problem se pokušava riješiti na razne načine. Jedan pristup su post-hoc metode (npr. SHAP^[4] ili perturbacijske metode^[5]), koje se primijene nakon treniranja modela na podacima te pokušavaju procijeniti važnost ulaznih značajki. Drugi čest pristup su mehanizmi pažnje (engl. attention^[6]) koji ističu dijelove ulaza na koje se model najviše oslanja. Ipak, u literaturi postoji rasprava koliko su težine pažnje stvarno pouzdano objašnjenje jer je moguće dobiti slične predikcije uz različite raspodjele pažnje^[7]. Također, postoje i arhitekture koje su interpretabilne po dizajnu, ali često imaju ograničenja (npr. rade samo za univarijatne nizove)^[8].

Stoga je cilj konstruirati arhitekturu dubokog učenja koja istovremeno postiže visoku točnost prognožiranja i daje objašnjenje svojih predikcija. Arhitektura dubokog učenja koja to pokušava napraviti zove se DC-Its (Duboki konvolucijski interpretator vremenskih nizova)^[1] i bit će detaljno opisana u sljedećem poglavlju. Ideja DCIts-a je da model uz predikciju također identificira koji se vremenski nizovi i koji vremenski pomaci (lagovi) najvažniji za predviđanje sljedeće vrijednosti. Cilj je da model ne radi samo dobre prognoze, nego da pomaže u razumijevanju dinamičkih sustava i daje jasne razloge za svoje predikcije.

2 Arhitektura DCIts

U ovom poglavlju opisujemo arhitekturu DCIts. Glavna ideja modela je da istovremeno radi prognozu i uči interpretabilne koeficijente koji opisuju koji vremenski niz utječe na koji i na kojem kašnjenju, tj. prijašnjoj vrijednosti (lagu) se taj utjecaj događa.

2.1 Jednadžba koju modeliramo

Multivarijantni sustav vremenskih nizova (MVS) sastoji se od N vremenskih nizova, od kojih je svaki duljine M , a zajednički ih prikazujemo kao $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_N)$. n -ti vremenski niz u ovom sustavu označava se s $\mathbf{X}_n = (X_{n,1}, X_{n,2}, \dots, X_{n,M})$, gdje $X_{n,t} \in \mathbb{R}$ označava vrijednost n -tog vremenskog niza u trenutku t . Ovdje $n = 1, 2, \dots, N \in \mathbb{N}$ indeksira nizove, a $t = 1, 2, \dots, M \in \mathbb{N}$ indeksira vremenske točke unutar svakog niza. Cilj nam je analizirati i protumačiti interakcije između različitih vremenskih nizova.

Za taj cilj se koristi DCIts. Ova arhitektura je dizajnirana da aproksimira prijelazni operator α , koji opisuje kako se vremenski nizovi razvijaju kroz vremenske korake. Vrijednost vremenskih nizova u sljedećem trenutku onda zapisujemo kao:

$$\mathbf{X}_{t+1} = \alpha \mathbf{Q}_t, \quad (5)$$

gdje $\mathbf{Q}_t$ sadrži L prijašnjih vrijednosti svakog vremenskog niza u MVS. Stoga je prvi korak podijeliti vremenske nizove u tzv. prozore. Definiramo prozor fiksne duljine L , pri čemu vrijedi $L < M$, te njime dijelimo MVS na preklapajuće intervale. Konstruiramo niz prozora $\mathbf{Q}_t$, pri čemu je svaki prozor definiran kao:

$$\mathbf{Q}_t = (\mathbf{X}_{t-L+1}, \dots, \mathbf{X}_{t-2}, \mathbf{X}_{t-1}, \mathbf{X}_t), \quad (6)$$

za $t = L, L+1, \dots, M$.

Može se primijetiti da susjedni prozori dijele većinu istih vrijednosti (pomiču se kroz vremenski niz s pomakom za jedan korak). Za skup svih prozora vrijedi $\mathbf{Q} \in \mathbb{R}^{(M-L+1) \times N \times L}$, gdje prva dimenzija označava broj uzoraka u skupu podataka, a $\mathbf{Q}_t$ predstavlja jedan pojedinačni uzorak. Cilj DCIts je aproksimirati prijelazni operator $\alpha \in \mathbb{R}^{N \times N \times L}$ za svaki uzorak $\mathbf{Q}_t$. Dimenzije tenzora α usklađene su s dimenzijama jednog uzorka $\mathbf{Q}_t$, pri čemu prve dvije dimenzije predstavljaju interakcije između vremenskih nizova, dok treća dimenzija odgovara lagu, odnosno vremenskom koraku. Na taj način, $\alpha_{n,i,j}$ objašnjava utjecaj i -tog vremenskog niza na lagu j na sljedeću vrijednost n -tog vremenskog niza u trenutku $t+1$.

Prijelazna jednadžba zatim glasi:

$$X_{n,t+1} = \sum_{i=1}^N \sum_{j=1}^L (\alpha \diamond \mathbf{Q}_t)_{n,i,j}. \quad (7)$$

gdje operator $\diamond$ označava element-po-element množenje članova na istim mjestima (Hadamardov produkt):


$$(\alpha \diamond \mathbf{Q}_t)_{n,i,j} = \alpha_{n,i,j} Q_{i,j}, \quad (8)$$

gdje je $\alpha \diamond \mathbf{Q}_t \in \mathbb{R}^{N \times N \times L}$ rezultatni tenzor po kojem se zatim sumira.


Osim prognoziranja, ovakav tenzorski zapis omogućuje i interpretaciju unutarnje dinamike MVS sustava. Točnije, omogućuje zaključivanje o jednadžbama koje generiraju promatrani multivarijantni vremenske nizovi.

2.2 Fokuser, Modeler i interpretabilnost

Cjelokupna arhitektura DCIts-a može se vidjeti na Slika 1. Kako bi došao do konačnog rezultata, DCIts prolazi kroz dvije faze. U prvoj fazi, nazvanoj Focuser, model identificira



Slika 1: ^[1] Slika prikazuje arhitekturu sustava DCIts na visokoj razini, koja se sastoji od dva modula: Fokuser i linearni Modeler. Modul Fokuser koristi ulazne podatke kako bi izračunao najvažnije podatkovne točke, odnosno nastoji utvrditi koji dijelovi ulaza najviše utječu na izlaz. Linearni Modeler računa linearne koeficijente za svaki vremenski niz i svaki pomak (lag), koji se zatim koriste za izračun sljedećeg koraka u vremenskom nizu. Rezultat $\mathbf{X}_t$ računa se kao umnožak ulaznih podataka, izlaza modula Fokusera i izlaza Modelera.



Slika 2: ^[1] Lijeva slika prikazuje arhitekturu modula Fokuser, dok desna slika prikazuje arhitekturu modula Modeler. Promatrajući njihove strukture, može se uočiti značajna sličnost u temeljnom dizajnu. Oba modula započinju nizom konvolucijskih slojeva, koji se potom spajaju i prosljeđuju kroz niz potpuno povezanih linearnih slojeva aktiviranih tanh funkcijama. Međutim, razlika se pojavljuje u završnom sloju: Fokuser koristi sigmoidnu funkciju kako bi eliminirao ulaze manje važnosti, čime učinkovito razlikuje šum od signala. Nasuprot tome, Modeler ne koristi aktivacijsku funkciju, s ciljem izračuna koeficijenata za svaku ulaznu vrijednost. Ovaj aspekt Modelera usko ga povezuje s načelima linearne regresije, pri čemu se ulazi tretiraju kao varijable unutar takvog okvira. Izostanak aktivacijske funkcije je namjeran, jer omogućuje neograničeno modeliranje koeficijenata. To je ključno, primjerice, pri modeliranju antikorelacije, što ne bi bilo moguće uz primjenu *ReLU* ili sličnih aktivacijskih funkcija.

značajne lagove i vremenske nizove, odnosno učinkovito odvajanje signal od šuma. Nakon toga slijedi faza Modeler, koja koristi informacije dobivene iz Fokuser-a, zajedno s početnim ulazom $\mathbf{Q}_t$, kako bi odredila konačne koefi-

jente prijelaznog tenzora α . Zatim, pomoću $\mathbf{Q}_t$ i α model radi konačne predikcije.

Fokuser i Modeler su izgrađeni na skoro istoj strukturi Slika 2, jedina razlika je u završnom sloju.

Ulaz Modelera i Fokusera prvo prolazi kroz niz konvolucijskih slojeva (Dodatak A) kako bi se obuhvatile i globalne i lokalne interakcije. U nastavku su navedeni slojevi i njihova uloga:

- **Globalni konvolucijski sloj** (dimenzije $N \times L$) – obrađuje sve vremenske nizove unutar prozora duljine L .
- **Vremenski konvolucijski sloj** (dimenzije $1 \times L$) – fokusira se na vremenske obrasce unutar jednog prozora kroz sve nizove.
- **Konvolucijski sloj po vremenskim nizovima** (dimenzije $N \times 1$) – hvata značajke preko svih vremenskih nizova u jednoj vremenskoj točki.
- **Sloj prvih susjeda** (dimenzije $N \times 3$) – analizira svaki vremenski niz i njihove neposredne susjede.
- **Sloj drugih susjeda** (dimenzije $N \times 5$) – proširuje analizu tako da uključuje i susjede drugog reda za svaki niz.
- **Sloj prvih susjeda za jedan niz** (dimenzije 1×3) – izolira jedan niz i analizira ga zajedno s njegovim neposrednim susjedima.
- **Sloj drugih susjeda za jedan niz** (dimenzije 1×5) – dodatno izolira jedan niz i analizira je zajedno sa susjedima drugog reda.

Zatim izlaze iz konvolucija spojimo u zajednički tenzor:

$$\mathbf{K} = \text{Concat}([\mathbf{K}_1, \mathbf{K}_2, \dots, \mathbf{K}_{CN}]). \quad (9)$$

gdje su $[\mathbf{K}_1, \mathbf{K}_2, \dots, \mathbf{K}_{CN}]$ pojedinačni izlazi iz gore nabrojanih konvolucijskih slojeva. Izlaz $\mathbf{K}$ se zatim provlači kroz tri potpuno povezana sloja (Dodatak A), pri čemu svaki koristi tanh aktivacijsku funkciju (Dodatak A). Konačni izlaz označavamo s $\mathbf{H} \in \mathbb{R}^{N \times N \times L}$.

To znači da svaki vremenski niz u sustavu generira matricu koja ima isti oblik kao ulaz. Razlog za ovakvu strukturu izlaza je da se za svaki vremenski niz može konstruirati prijelazni tenzor, pri čemu prva dimenzija izlaza omogućuje iteraciju preko ulaznih vremenskih nizova.

Završni sloj u Modeleru je potpuno povezani sloj kojim se računa tenzor $\mathbf{C} \in \mathbb{R}^{N \times N \times L}$:

$$\mathbf{C} = \mathbf{W}_H \mathbf{H} + \mathbf{b}_H. \quad (10)$$

Tenzorom $\mathbf{C}$ želimo dobiti amplitudu i predznak elemenata prijelaznog tenzora α . Amplituda govori koliki je utjecaj elemenata tenzora na izlaz, a predznak ukazuje na korelacije i anti-korelacije koje postoje u sustavu.

Za Fokuser se još dodatno na tenzor $\mathbf{H}$ primjenjuje sigmoida, čime se dobiva tenzor $\mathbf{F}$:

$$\mathbf{F} = \sigma(\mathbf{H}). \quad (11)$$

Ovdje $\sigma(x)$ označava sigmoidnu funkciju:

$$\sigma(x) = \frac{1}{1 + e^{-x}}. \quad (12)$$

Elementi tenzora $\mathbf{F}$ nalaze se u rasponu $(0, 1)$, odnosno $F_{i,j,k} \in (0, 1)$. Svrha tenzora $\mathbf{F}$ je razlikovati šum od signala te pomoći modelu da identificira koji dijelovi prozora $\mathbf{Q}_t$ zaslužuju pažnju.

Razlika između Modelera i Fokusera je i u ulazu, ulaz u Modeler nije izravno $\mathbf{Q}_t$, nego $\mathbf{F} \diamond \mathbf{Q}_t$. Konačno, kako bismo dobili izlaz modela, potrebno je ubaciti i $\mathbf{F}$ i $\mathbf{C}$:

$$X_{n,t+1} = \sum_{i=1}^N \sum_{j=1}^L \left(((\mathbf{C} \circ \mathbf{F}) \diamond \mathbf{Q}_t)_{n,i,j} \right), \quad (13)$$

gdje je $\circ$ Hadamardov produkt generaliziran na tenzore višeg reda:

$$(\mathbf{C} \circ \mathbf{F})_{i,j,k,\dots} = C_{i,j,k,\dots} F_{i,j,k,\dots}. \quad (14)$$

Usporedbom prethodnog zapisa s jednadžbom za prijelazni tenzor dobivamo:

$$\alpha = \mathbf{C} \circ \mathbf{F}. \quad (15)$$

Dakle, prijelazni tenzor α dobiva se kao Hadamardov produkt izlaza Fokusera ($\mathbf{F}$) i izlaza Modelera ($\mathbf{C}$). Model ne može napraviti

predikciju bez toga da istovremeno proizvede i interpretabilne koeficijente. Osim toga, tenzori $\mathbf{F}$ i $\mathbf{C}$ računaju se za svaki korak (i tijekom treniranja i tijekom testiranja), što omogućuje lokalno objašnjenje, tj. možemo razumjeti zašto je model donio baš određenu predikciju za svaki pojedini uzorak. Interpretabilnost se pritom ne uprosječuje preko svih uzo-

raka, jer bi uprosječenje moglo sakriti dio dinamike sustava; umjesto toga, model daje interpretaciju za svaki pojedini uzorak.

Budući da imamo skup od $M - L + 1$ uzoraka, postojat će jednaki broj koeficijenata α , pri čemu svaki odgovara jednom određenom uzorku i označava se kao α_t .

3 Točnost i robusnost arhitekture

U ovom poglavlju provjeravamo točnost modela u prognoziranju različitih skupova podataka i koliko je robusan na tipične probleme realnih podataka.

3.1 Treniranje i točnost modela

DCIts se trenira tako da kao ulaz koristi prozor $\mathbf{Q}_t$ i predviđa $\mathbf{X}_{t+1}$, a zatim se težine modela prilagođavaju tako da se predikcije što bolje poklapaju sa stvarnim vrijednostima. Važno je naglasiti da se model ne trenira direktno na interpretabilnost, nego na zadatak prognoziranja. Interpretabilnost (tenzor α_t) pojavljuje se kao intrinzično svojstvo arhitekture.

Treniranje znači pronaći koeficijente modela za koje dobivamo najmanje odstupanje između predikcija i stvarnih vrijednosti. Kao i kod drugih modela dubokog učenja, to se postiže algoritmom unatragne propagacije (engl. backpropagation), uz standardne dobre prakse strojnog učenja (Dodatak A).

Postupak treniranja i dobivanja interpretabilnosti sažet je u Algoritam 1.

Implementacija DCIts-a napravljena je u Pythonu, koristeći knjižnicu PyTorch, a kod se može vidjeti na GitHub-u^[9]. Prije treniranja, od originalnih vremenskih nizova konstruiraju se prozori $\mathbf{Q}_t$ duljine L i od njih se napravi trodimenzionalni tenzor $\mathbf{Q} \in \mathbb{R}^{(M-L+1) \times N \times L}$. Taj skup se zatim dijeli na trening, validacijski i testni dio.

Algoritam 1 Izdvajanje interpretabilnosti iz multivarijatnih vremenskih nizova

Ulaz: Skup uzoraka s prozorima $\mathbf{Q}$

Ulaz: Funkcija gubitka $\mathcal{L}$

Podijeli skup uzoraka $\mathbf{Q}$ na skup za treniranje

$\mathbf{Q}_{\text{train}}$, validaciju $\mathbf{Q}_{\text{val}}$ i testiranje $\mathbf{Q}_{\text{test}}$

Promiješaj skup za treniranje $\mathbf{Q}_{\text{train}}$

Treniraj model $\mathcal{M}_{\text{DCIts}}$ na $\mathbf{Q}_{\text{train}}$

Evaluiraj model na $\mathbf{Q}_{\text{val}}$ koristeći $\mathcal{L}$

ako validacijski gubitak se ne poboljšava kroz unaprijed zadani broj iteracija **onda**

 Zaustavi treniranje ranije

 ▷ Rano zaustavljanje temeljeno na validacijskim performansama

kraj ako

za svaki $\mathbf{Q}_{t,\text{test}} \in \mathbf{Q}_{\text{test}}$ **radi**

 Izvedi inferenciju treniranim modelom

$\mathcal{M}_{\text{DCIts}}$ nad $\mathbf{Q}_{t,\text{test}}$

 Izračunaj matrice $\mathbf{F}_{t,\text{test}}$ i $\mathbf{C}_{t,\text{test}}$ za $\mathbf{Q}_{t,\text{test}}$

 Izračunaj prijelazni tenzor $\alpha_{t,\text{test}}$ kao

$\alpha_{t,\text{test}} = \mathbf{F}_{t,\text{test}} \circ \mathbf{C}_{t,\text{test}}$

kraj za

Učenje je provedeno s dvije različite funkcije gubitka $\mathcal{L}$: MSE (Mean Squared Error) i MAE (Mean Absolute Error):

$$\begin{aligned} \text{MSE} &= \frac{1}{T} \sum_{k=1}^T (y_k - \hat{y}_k)^2, \\ \text{MAE} &= \frac{1}{T} \sum_{k=1}^T |y_k - \hat{y}_k|. \end{aligned} \tag{16}$$

gdje su y_k stvarne vrijednosti, a $\hat{y}_k$ predikcije modela za sve vremenske točke i sve nizove u

testnom skupu. T je ukupan broj podataka.

Za optimizaciju se koristi Adam optimizator, learning rate 10^{-3} i batch size 64. U svakoj epohi model prolazi kroz sve prozore u trening skupu, računa predikcije $\hat{\mathbf{X}}_{t+1}$ te na temelju funkcije gubitka $\mathcal{L}$ ažurira težine konvolucijskih i potpuno povezanih slojeva, a time neizravno i vrijednosti tenzora $\mathbf{F}$, $\mathbf{C}$ i α . Na kraju svake epohe mjeri se gubitak na validacijskom skupu; ako se on neko vrijeme ne poboljšava, treniranje se zaustavlja (early stopping) kako bi se izbjeglo prenaučanje.

U radu^[1] DCITs je testiran na nizu sintetičkih multivarijatnih vremenskih nizova koje su konstruirane tako da je poznata točna dinamika sustava i stvarne interakcije između nizova. Izgled testiranih vremenskih nizova vidljiv je na^[10]. U najjednostavnijim skupovima podataka svaki niz ovisi samo o vlastitim prošlim vrijednostima (autoregresijski procesi). U složenijim primjerima dodaju se unakrsne korelacije (jedan niz pobuđuje drugi), kombinacije više lagova te mješavina pozitivnih i negativnih utjecaja. Najzahtjevniji skupovi uključuju promjenu dinamike u vremenu (prebacivanje između dva različita režima) i nelinearne pojave (npr. kubični član u jednadžbi). U numeričkim eksperimentima za različite skupove podataka dobivaju se vrlo male vrijednosti MSE-a (10^{-5} do 10^{-3}), što znači da DCITs uspješno rekonstruira dinamiku sustava i daje precizne prognoze. Rezultati za različite skupove podataka iz^[10] vidljivi su u Tablica 1.

Tablica 1: ^[1]u tablici je prikazana prosječna srednja kvadratna pogreška (MSE) za DCITs model na skupovima podataka iz^[10].

Skup podataka	DCITs (MSE)
1	$(2.98 \pm 0.01) \times 10^{-3}$
2	$(7.58 \pm 0.02) \times 10^{-4}$
3	$(6.17 \pm 0.15) \times 10^{-5}$
4	$(1.23 \pm 0.01) \times 10^{-4}$
5	$(1.25 \pm 0.01) \times 10^{-3}$
6	$(1.27 \pm 0.02) \times 10^{-3}$
7	$(3.10 \pm 0.03) \times 10^{-3}$
8	$(2.55 \pm 0.49) \times 10^{-2}$

Zajedničko svim skupovima podataka je da se početne vrijednosti nizova zadaju iz normalne raspodjele $N(0, 1)$, a zatim se sustav razvija prema zadanim jednadžbama uz Dodatak A šuma. U svakoj vremenskoj točki na signal se dodaje Gaussov šum ε_t koji se pojavljuje s određenom frekvencijom f (npr. $f = 0,3$) i varijancom σ_{noise}^2 (npr. $\sigma_{\text{noise}}^2 = 0,1$):

$$\epsilon_t = \begin{cases} \mathcal{N}(0, \sigma_{\text{noise}}^2), & \text{ako } p < f, \\ 0, & \text{inače.} \end{cases} \quad (17)$$

gdje je p slučajan broj iz uniformne raspodjele na intervalu $(0, 1)$. Pokazuje se da točnost modela ne opada značajno s povećanjem frekvencije šuma.

Osim srednje pogreške, gleda se i stabilnost modela kada se treniranja ponove više puta s različitim inicijalizacijama te se rezultati uprosječuju kroz sva treniranja.

Naravno, u praksi ne znamo uvijek točnu duljinu prozora L koja je dovoljno velika da uhvati sve važne interakcije, ali ne prevelika da model postane nepotrebno kompliciran. U numeričkim eksperimentima vidi se da je DCITs robustan na izbor veličine prozora te da je dovoljno odabrati prozor koji je dovoljno velik, čak i ako premašuje stvarnu vrijednost.

3.2 Robusnost modela na nepravilne podatke

Podaci iz realnih eksperimentalnih mjerenja najčešće nisu savršeni, sadrže šum ili imaju propuštena mjerenja. Zato je cilj testirati koliko je DCITs robustan na takve nepravilnosti u podacima. U ovom poglavlju fokusiramo se na sedmi skup podataka (Dataset 7)^[10], definiran sljedećim sustavom jednadžbi:

$$\begin{aligned} X_{1,t} &= \alpha_{1,1,1}^{\text{gt}} X_{1,t-1} + \alpha_{1,1,5}^{\text{gt}} X_{1,t-5} + \varepsilon_{1,t}, \\ X_{2,t} &= 1 + \alpha_{2,1,2}^{\text{gt}} X_{1,t-2} + \varepsilon_{2,t}, \\ X_{3,t} &= \alpha_{3,2,1}^{\text{gt}} X_{2,t-1} + \alpha_{3,4,4}^{\text{gt}} X_{4,t-4} + \varepsilon_{3,t}, \\ X_{4,t} &= 1 + \alpha_{4,3,4}^{\text{gt}} X_{3,t-4} + \alpha_{4,5,1}^{\text{gt}} X_{5,t-1} + \varepsilon_{4,t}, \\ X_{5,t} &= \alpha_{5,5,4}^{\text{gt}} X_{5,t-4} + \alpha_{5,2,1}^{\text{gt}} X_{2,t-1} + \varepsilon_{5,t}. \end{aligned} \quad (18)$$

Pravi (ground truth) koeficijenti u ovom sustavu su:

$$\begin{aligned} \alpha_{1,1,1}^{\text{gt}} &= \frac{1}{4}, & \alpha_{1,1,5}^{\text{gt}} &= \frac{3}{4}, \\ \alpha_{2,1,2}^{\text{gt}} &= -1, & \alpha_{3,4,4}^{\text{gt}} &= 1, \\ \alpha_{3,2,1}^{\text{gt}} &= 1, & \alpha_{4,5,1}^{\text{gt}} &= -\frac{5}{7}, \\ \alpha_{4,3,4}^{\text{gt}} &= -\frac{2}{7}, & \alpha_{5,2,1}^{\text{gt}} &= \frac{10}{22}, \\ \alpha_{5,5,4}^{\text{gt}} &= \frac{12}{22}, \end{aligned} \quad (19)$$

Sve numeričke analize u ovom poglavlju odrađene su lokalno na računalu s procesorom Intel i5-14400F, grafičkom karticom NVIDIA RTX 5070 i 32 GB RAM-a. U svim testovima za Dataset 7 koristi se frekvencija šuma $f = 1$, što znači da je šum prisutan u svakoj vremenskoj točki. Testiranje se vrši na tri scenarija, otpornost na povećanje razine šuma, otpornost na nedostajuće podatke i otpornost na promjenu dinamike u neviđenim podacima. Sva treniranja i testiranja provedena su na isti način kao u prethodnom poglavlju, uz višestruko treniranje za različite inicijalizacije.

3.2.1 Robusnost modela na razinu šuma u podacima

U prvom scenariju testiramo kako razina šuma utječe na točnost prognoze modela DCIts na skupu podataka 7. Dinamički sustav je definiran jednadžbama (18), pri čemu na svaki vremenski niz u svakoj vremenskoj točki dodajemo Gaussov šum ε_t (17) s nul-sredinom i standardnom devijacijom σ .

U testu robusnosti mijenjamo standardnu devijaciju šuma u rasponu:

$$\sigma \in \{0.1, 0.2, 0.4, 0.6, 0.8, 1.0, 2.0, 3.0\}.$$

Za svaku vrijednost σ generiramo novi skup vremenskih nizova duljine $T = 20000$, a zatim model treniramo više puta s istim hiperparametrima kao u prethodnom poglavlju. Na kraju mjerimo korijen srednje kvadratne pogreške (RMSE) na testnom skupu. Dobiveni RMSE za pojedine razine šuma vidljivi

su u Tablica 2. Vidimo da RMSE gotovo kompletno odgovara standardnoj devijaciji šuma, što pokazuje da je greška modela gotovo kompletno objašnjena šumom dok je model, kao što ćemo vidjeti u nastavku, ispravno naučio dinamiku sustava.

U Tablica 4 možemo vidjeti koliko se procijenjeni koeficijenti α razlikuju od stvarnih (ground truth) koeficijenata u sustavu za najveću i najnižu razinu šuma. Za sve testirane razine šuma prosječna apsolutna razlika između procijenjenih i stvarnih α -koeficijenata ostaje mala, a elementi koji ne postoje u stvarnom sustavu ostaju blizu nule. To znači da model, čak i u prisutnosti jakog šuma, ne gubi interpretabilnost i dalje ispravno prepoznaje koji su utjecaji između nizova stvarno prisutni, a koji nisu.

Također, ako promotrimo Slika 3. možemo vidjeti da za procjenu koeficijenata određeni izvor šuma zapravo pozitivno doprinosi boljem predviđanju koeficijenata.


Tablica 3 prikazuje naučene koeficijente pristranosti (bias) modela za najveću i najnižu razinu šuma. Predikcije ostaju dobre za sve razine jakosti šuma.

Tablica 2: Ovisnost pogreške predikcije (RMSE) modela DCIts o razini šuma σ na skupu podataka 7.

σ	RMSE
0.1	(0.1009 ± 0.0002)
0.2	(0.20105 ± 0.00009)
0.4	(0.4021 ± 0.0006)
0.6	(0.606 ± 0.002)
0.8	(0.807 ± 0.003)
1.0	(1.017 ± 0.008)
2.0	(2.03 ± 0.01)
3.0	(3.05 ± 0.01)

Tablica 3: Procijenjeni koeficijenti pristranosti (bias) za svih pet vremenskih nizova na skupu podataka 7, za najmanju i najveću razinu šuma.

Niz	bias^{gt}	$\text{bias}_{\sigma=0,1}$	$\text{bias}_{\sigma=3,0}$
X_1	0,00	$0,04 \pm 0,01$	$0,06 \pm 0,02$
X_2	1,00	$0,94 \pm 0,01$	$0,91 \pm 0,03$
X_3	0,00	$0,04 \pm 0,03$	$0,084 \pm 0,007$
X_4	1,00	$0,981 \pm 0,009$	$1,03 \pm 0,03$
X_5	0,00	$0,003 \pm 0,005$	$0,05 \pm 0,03$




Slika 3: Slike prikazuju predviđanja ne-nultih koeficijenata $\alpha_{n,i,l}$, zajedno s njihovim standardnim devijacijama, za sve vremenske nizove i za svaku testiranu razinu šuma. Vidljivo je da DCIts dobro rekonstruira koeficijente za sve razine šuma, a da određena razina šuma čak i doprinosi boljoj rekonstrukciji koeficijenata.

Tablica 4: Procijenjeni koeficijenti $\alpha_{n,i,l}$ za najmanju i najveću razinu šuma na skupu podataka 7. Prikazani su samo elementi koji nisu nula.

Koef.	α^{gt}	$\alpha (\sigma = 0,1)$	$\alpha (\sigma = 3,0)$
$\alpha_{1,1,1}$	0,25	$0,231 \pm 0,007$	$0,213 \pm 0,008$
$\alpha_{1,1,5}$	0,75	$0,73 \pm 0,01$	$0,73 \pm 0,01$
$\alpha_{2,1,2}$	-1	$-0,973 \pm 0,008$	$-1,00 \pm 0,02$
$\alpha_{3,2,1}$	1	$0,96 \pm 0,03$	$1,00 \pm 0,02$
$\alpha_{3,4,4}$	1	$0,96 \pm 0,03$	$1,01 \pm 0,03$
$\alpha_{4,3,4}$	-0,2857	$-0,283 \pm 0,006$	$-0,29 \pm 0,02$
$\alpha_{4,5,1}$	-0,7143	$-0,692 \pm 0,006$	$-0,70 \pm 0,01$
$\alpha_{5,2,1}$	0,4545	$0,44 \pm 0,01$	$0,43 \pm 0,02$
$\alpha_{5,5,4}$	0,5455	$0,551 \pm 0,008$	$0,544 \pm 0,007$

3.2.2 Robusnost modela na nedostajuće podatke

U realnim fizikalnim mjerenjima podaci gotovo nikad nisu savršeni, često nedostaju mjerenja, ili su neke točke neispravne pa ih je potrebno odbaciti. Zato je važno provjeriti kako se DCIts ponaša kada na ulazu dobije vremenske nizove s nasumično izbrisanim dijelovima, koje zatim popunjavamo (imputiramo) jednostavnim metodama. Prvo se generira čisti multivarijatan vremenski niz prema jednadžbama za skup podataka 7.



Slika 4: Slike prikazuju RMSE na testnom skupu u ovisnosti o postotku nedostajućih vrijednosti za tri različite metode imputacije, kada podaci nedostaju unutar testnog skupa (gornja slika) i unutar treniranih skupa (donja slika). U oba slučaja linearna interpolacija pokazuje najbolje rezultate imputacije, dok nedostatak podataka u treniranih skupu značajnije narušava predviđanja DCIits-a, što upućuje na važnost potpunih podataka za učinkovito učenje modela.

Zatim se u svakom vremenskom nizu nasumično izbriše određeni postotak točaka. Posebno testiramo slučaj kada podaci nedostaju samo u skupu za treniranje i slučaj kada podaci nedostaju samo u skupu za testiranje. U oba slučaja promatramo četiri različita udjela nedostajućih podataka: 1 %, 2 %, 5 % i 10 % ukupnog broja točaka.

Prije treniranja modela potrebno je nedostajuće vrijednosti popuniti (imputirati). Posebno se testiraju tri različite imputacije za svaki od gore navedenih slučajeva, a to su: linearna interpolacija, imputacija prethodnom vrijednošću i imputacija srednjom vrijednošću.

Može se primijetiti da se arhitektura bolje

snalazi kada je trenirana na kompletnim podacima i kada se testira na interpoliranim podacima, tada greška ne raste drastično s povećanjem nedostajućih podataka u testnom skupu. Međutim, kada podaci nedostaju u skupu za treniranje, a testiraju se na kompletnom skupu, onda se vidi puno veći porast greške s brojem nedostajućih podataka (Slika 4).

Od tri metode interpolacije, linearna interpolacija je najviše doprinijela robusnosti arhitekture na nedostajuće podatke, što sugerira da bi kompleksnije metode interpolacije mogle dovesti do još veće robusnosti.

Unatoč povećanju nedostajućih podataka. DCIits i dalje uspješno prepoznaje glavnu strukturu tenzora α , položaje nenultih koeficijenata, njihov predznak (korelacija/antikorelacija) i vrijednosti za sve postotke nedostajućih vrijednosti.

3.2.3 Robusnost modela na promjenu dinamike u neviđenim podacima


U skupu podataka 8 pokazano je da, kada je arhitektura trenirana na sustavu u kojem se dinamika mijenja, može i na testnom skupu dobro prepoznati trenutak promjene i novu dinamiku^[1]. U ovom poglavlju testiramo koliko je model robusan ako je treniran na jednoj dinamici, a zatim se dinamika promijeni samo u testnom skupu podataka, tj. ako dođe do promjene elemenata tenzora α koju model nikad ranije nije vidio.

Vremenski niz je izgeneriran tako da prva polovica prati dinamiku Datasetsa 7 (dinamika A), dok u drugoj polovici dođe do promjene dinamike (dinamika B). U drugoj dinamici B mijenjamo koeficijente tako da:


$$\alpha_{3,4,4}^{(B)} = 0.0, \quad \alpha_{3,3,4}^{(B)} = 0.5$$

Pri čemu se u drugom dijelu koristi ista razina šuma kao u prvom dijelu, a početno stanje za dinamiku B uzima se iz zadnjih L vrijednosti dinamike A. Time se izbjegava umjetni skok u samim vrijednostima nizova, a promjena je isključivo u dinamici (u koeficijentima). Model je treniran samo na prvoj

Usporedba stvarne i predviđene 3. vremenske serije u 2. dinamici



Usporedba stvarne i predviđene 5. vremenske serije u 2. dinamici




Slika 5: Slike prikazuju predviđanja vrijednosti vremenskih prozora u drugoj dinamici za treći vremenski niz (gornja slika) i peti vremenski niz (donja slika). Vidljivo je da DCIts i dalje uspijeva predvidjeti trend vremenskih nizova, no predviđene vrijednosti značajno odstupaju od stvarnih.


polovici, a testiran na obje polovice (zbog jednostavnosti) kako bi se vidjelo, može li model uočiti da je došlo do promjene dinamike i može li točno predvidjeti kako se dinamika promijenila.

RMSE na drugoj polovici podataka iznosi $RMSE = 5.0503817 \pm 1.1439577$, a predviđanja za pojedine prozore u 2. dinamici vidljivi su na Slika 5. Greška na podacima gdje je došlo do promjene dinamike je velika, ali je uhvaćen trend vremenskih nizova.

Evolucija $\alpha_{554}(GT = 0.545)$



Usporedba promijenjenih koeficijenata: $\alpha_{3,3,4}$ i $\alpha_{3,4,4}$



Slika 6: Slike prikazuju predviđanje koeficijenata za vremenske prozore u drugoj dinamici za α_{554} (gornja slika) te α_{334} i α_{344} , koji su doživjeli promjenu (donja slika). Vidljivo je da DCIts može predvidjeti trenutak promjene koeficijenata koji su se stvarno promijenili, no predviđene vrijednosti tih koeficijenata, kao i koeficijenata koji se nisu promijenili, značajno odstupaju od stvarnih te imaju veliku standardnu devijaciju.

Na Slika 6 se može vidjeti da model odmah prepozna kada dođe do promijene u dinamici, ali vrijednosti promijenjenih koeficijenata nisu dobro predviđene. Isto tako, nakon prijelaza ni koeficijenti koji se u stvarnosti nisu promijenili više nisu točno procijenjeni. Dodatno, pri ponavljanju eksperimenta s različitim inicijalizacijama, dobivaju se relativno velike standardne devijacije koeficijenata dinamike B, što znači da su rezultati osjetljivi na početne uvjete treniranja i nisu konzistentni.

Zaključno, arhitektura može “osjetiti” da se dinamika sustava promijenila, ali ne uspijeva pouzdano naučiti novi skup koeficijenata ako takav tip promjene nije bio prisutan u trening podacima. Drugim riječima, DCIts nije robustan na nagle promjene dinamike koje nisu videne tijekom treniranja.

4 Primjena na fizikalnom sustavu

U ovom poglavlju primjenjujemo DCIts model na simulirane fizikalne podatke. Kao fizikalni sustav odabrana je populacija neurona, čije se ponašanje može opisati multivarijantnim vremenskim nizovima. Ova primjena temelji se na radu Bartola Pavlovića^[11], koji je koristio simulacije Izhikevichev modela dinamike neurona, generirane simulatorom Brian 2. Cilj je reproducirati rezultate rada na drugačijoj konfiguraciji neurona te pokazati kako DCIts može predvidjeti dinamiku sustava i prepoznati najbitnije interakcije.

4.1 Neuroni i prijenos informacija akcijskim potencijalima

Neuron je osnovna jedinica živčanog sustava, specijalizirana stanica koja prima, obrađuje i prenosi informacije. Osnovna građa neurona sastoji se od tri glavna dijela: soma, dendriti i aksoni. Soma sadrži jezgru i većinu staničnog metabolizma. Dendriti su razgranati produžeci koji primaju signale od drugih neurona, dok akson prenosi signale dalje prema drugim neuronima. Specijalizirana mjesta za prijenos signala, električnog impulsa, s jednog neurona na drugi zovu se sinapse. Taj električni impuls, tzv. akcijski potencijal, nastaje na početku aksona te putuje niz njega. Sposobnost neurona da promjeni vlastiti električni potencijal membrane omogućuje slanje signala niz akson. Taj električni potencijal zove se akcijski potencijal. Međutim, za opis dinamike slanja signala između velikog broja neurona nije potreban detaljan opis kemijskog sastava neurona niti detaljno poznavanje izgleda akcijskog potencijala, bitno je samo opisati proces stvaranja impulsa i integriranje signala s drugih neurona. Za detaljan opis izgleda akcijskog potencijala i kemijskog procesa unutar neurona, vidjeti^[11].

4.2 Izhikevichev model neurona

Za modeliranje neuronske dinamike koristi se Izhikevichev model^[12], koji je jednostavan, ali dovoljno fleksibilan da reproducira različita

ponašanja stvarnih neurona. Model se sastoji od dvije diferencijalne jednačbe koje opisuju membranski potencijal v i varijablu oporavka membrane u :

$$\begin{aligned}\frac{dv}{dt} &= 0.04v^2 + 5v + 140 - u + I, \\ \frac{du}{dt} &= a(bv - u),\end{aligned}\tag{20}$$

s dodatnim pravilom resetiranja:

$$\text{ako } v \geq v_{\text{prag}} \Rightarrow \begin{cases} v \leftarrow c, \\ u \leftarrow u + d. \end{cases}\tag{21}$$

Ovdje I predstavlja sinaptičke struje, a parametri a , b , c i d određuju tip neurona. Dodavanjem šuma (npr. Gaussovog šuma na ulaznu struju) model može simulirati stohastičke efekte u stvarnim neuronskim mrežama. Model nije izravno fiziološki (ne simulira kemijske procese membrane), ali dovoljno dobro aproksimira biološka svojstva da bude koristan u simulacijama mreža i u istraživanjima neuronske dinamike na sustavnoj razini.

4.3 Simulirana mreža neurona i treniranje interpretabilnog modela

Generiranje podataka Izhikevichevim modelom

Za generiranje podataka korišten je paket Brian 2^[13], simulator za mreže neurona napisan u programskom jeziku Python. Paket omogućuje jednostavno modeliranje i simuliranje neuronskih mreža, uključujući različite vrste neurona i sinaptičke veze među njima. U simulaciji je korišteno 20 neurona podijeljenih na 14 pobuđujućih i 6 inhibirajućih neurona. Pobuđujući neuroni doprinose povećanju potencijala na povezanim neuronima (pozitivne sinapse), dok inhibicijski neuroni ga smanjuju (negativne sinapse). Jačina sinapsi između neurona određena je matricom težina w , gdje

su težine iz uniformne distribucije unutar intervala $[0, 0.5>$ za pobuđujuće i $<0, -1]$ za inhibirajuće neurone.

Parametri Izhikievichevog modela glase: $v_{\text{prag}} = -45\text{mV}$, $a = 0.02$, $b = 0.25$, $c = -50$, $d = 8$, uz dodanu nasumičnost reda veličine 5% kako neuroni ne bi bili identični.

U simulaciji, sinaptičke veze definirane su tako da nakon generiranja impulsa presinaptirajući neuron dodaje konstantan član $I = s \cdot w$ (gdje je $s=20$) u jednadžbu potencirajućeg neurona sa zakašnjenjem od $t_{\text{on}} = 2$, a taj doprinos se gasi $t_{\text{off}} = 3$ ms nakon generiranja impulsa. Gaussov šum je dodan u jednadžbu pri svakom koraku integracije.

Generiranjem podataka za 20 neurona dobiveno je 40 vremenskih nizova, 20 vremenskih nizova potencijala v i 20 vremenskih nizova u . Vremenska rezolucija je 1 ms, a vrijeme trajanja simulacije je 10 s, što daje ukupno 40 vremenskih nizova s po 10000 vremenskih točaka. Prilikom biranja parametara, pazilo se da ponašanje okidanja neurona ostane stabilno tijekom cijelog trajanja simulacije.

Jednadžba (20) se može diskretizirati korištenjem Eulerove metode i zatim napisati u obliku pogodnom za učenje DCIts modelom i, uz poštivanje Einsteinove konvencije o sumaciji, za vremenski trenutak t i lag l glasi:

$$X_{i,t} = \alpha_i^{(0)} + \alpha_{ijl}^{(1)} X_{jl} + \alpha_{ijl}^{(2)} X_{jl}^2 + I_{ijl} \theta(X_{jl} - X_j^{\text{prag}}) \quad (22)$$

gdje su:

$$X_i = \begin{bmatrix} v_i \\ u_i \end{bmatrix}, \quad X_i^2 = \begin{bmatrix} v_i^2 \\ u_i^2 \end{bmatrix},$$

$$I = \begin{bmatrix} I_{vv}(t) & I_{vu}(t) \\ I_{uv}(t) & I_{uu}(t) \end{bmatrix}.$$

gdje koeficijenti uz članove moraju biti:

$$\alpha_i^{(0)} = \begin{bmatrix} 140 \\ 0 \end{bmatrix},$$

$$\alpha_{ij0}^{(1)} = \begin{bmatrix} 1+5 & -1 \\ a_i b_i & 1-a_i \end{bmatrix}, \quad \alpha_{ijl}^{(1)} = 0 \text{ za } l \neq 0,$$

$$\alpha_{ij0}^{(2)} = \begin{bmatrix} 0.04 & 0 \\ 0 & 0 \end{bmatrix}, \quad \alpha_{ijl}^{(2)} = 0 \text{ za } l \neq 0.$$

Ako pretpostavimo da je ulazna struja sinaptičkih veza konstantna i doprinosi samo u vremenskim koracima S , zadnji član je:

$$I_{ijk} = \begin{bmatrix} sw\delta_{ik} & 0 \\ d\delta_{ik} & 0 \end{bmatrix}, \quad \text{za } l \in S, \quad \text{inače } I_{ijl} = 0.$$

Svi neuroni imaju isti prag X^{prag} , stoga vrijedi:


$$X_i^{\text{prag}} = \begin{bmatrix} -45 \\ 0 \end{bmatrix}.$$

Rezultati za 10 nezavisnih iteracija treniranja modela pokazuju da je prosječna vrijednost L1 pogreške na testnim podacima iznosi 0.109 uz standardnu devijaciju od 0.002, što ukazuje na stabilno i konzistentno učenje modela. Rezultati učenja koeficijenata vidljivi su na Slika 7

Koeficijenti linearnog člana $\alpha_{ij0}^{(1)}$ jasno pokazuju blok-dijagonalnu strukturu, što znači da model uspješno prepoznaje da dinamika pojedinog neurona ovisi prvenstveno o vlastitim prethodnim vrijednostima potencijala v_{t-1} i varijable oporavka u_{t-1} , bez značajne izravne korelacije s drugim neuronima.

Slično ponašanje uočeno je kod kvadratičnih koeficijenata $\alpha_{ij0}^{(2)}$ i koeficijenata sinaptičkih veza I_{ij} . Iako su predviđene vrijednosti ovih parametara nešto veće od referentnih, njihov red veličine ostaje konzistentan, što se može pripisati prisutnosti šuma u simuliranim podacima.

Na kraju, prosječna predviđena vrijednost praga potencijala iznosi $\bar{v}^{\text{prag}} = (-53 \pm 3) \text{mV}$, što značajno odstupa stvarnoj vrijednosti korištenoj u simulaciji. Moguće je da odstupanje proizlazi iz grublje diskretizacije Eulerovom metodom, zbog čega prag okidanja



Slika 7: Gornji red: prosječne vrijednosti parametara za 10 iteracija treniranja modela. Prikazani su samo najbitniji parametri, to jest $\alpha_{ij0}^{(1)}$, $\alpha_{ij0}^{(2)}$, I_{ij2} . Donji red: Referentne vrijednosti navedenih parametara označavaju njihove stvarne vrijednosti. Vrijednosti svih parametara i njihovi rasponi prikazani su ljestvicama boja pokraj grafova.

u promatranim uzorcima jako varira. Druge metode diskretizacije i simulacije podataka, mogle bi dovesti do veće konzistentnosti između simulacije i zadanih parametara.

Rezultati potvrđuju da DCIts model postiže dobru točnost predviđanja i uspješno uči bitne parametre koji odgovaraju onima korištenim u simulaciji.

5 Zaključak

U ovom seminaru istražili smo primjenu interpretabilnih modela dubokog učenja za prognozu multivarijatnih vremenskih nizova, s naglaskom na fizikalne sustave. Počevši od osnovnih pojmova vremenskih nizova i linearnih modela, istaknuli smo ograničenja interpretabilnosti dubokih modela koji često postižu veće točnosti od jednostavnijih interpretabilnih modela. Problem interpretabilnosti dubokih modela riješen je kroz detaljan opis arhitekture DCIts (Duboki konvolucijski interpretator vremenskih nizova), koji istovremeno postiže visoku prediktivnu točnost i pruža jasne uvide u in-

terakcije između vremenskih nizova.

Analiza robusnosti modela na šum i nepravilnosti u podacima pokazala je da DCIts učinkovito odvaja dinamiku sustava od šuma, neovisno o razini jakosti šuma. Također, na primjeru nedostajućih podataka i promjene dinamike, pokazano je da je za pravilan opis sustava ipak ključno imati kompletan skup za treniranje koji je vidio cijelu dinamiku sustava.

Primjena modela na simuliranoj mreži neurona opisanoj Izhikevichevim modelom demonstrirala je njegovu sposobnost da otkrije ključne dinamike sustava, s visokom

točnošću prognoze i interpretabilnim rezultatima koji omogućuju rekonstrukciju originalne dinamike.

Rezultati ukazuju da DCIts predstavlja vrijedan alat za otkrivanje dinamike fizikalnih sustava, spajajući prednosti dubokog učenja s interpretabilnošću tradicionalnih metoda, što je ključno u fizici i ostalim područjima.

Buduća istraživanja mogla bi se usm-

jeriti za proučavanje kompleksnijih metoda za pripremu nepravilnih podataka za učenje modela, kao što su kompleksnije metode interpolacije. Također, ključno je testirati model na podacima iz stvarnih eksperimentalnih mjerenja te pokušati rekonstruirati dinamiku sustava i demonstrirati korisnost ovakvih alata u stvarnom istraživanju i realnim situacijama.

Dodatak A

Ovaj dodatak prolazi kroz osnove osnova strojnog učenja, kako bi bilo lakše pratiti sve komponente seminara. Za detaljniji pregled spomenutih tema, pogledati^[14].

Potpuno povezani sloj mapira vektor ulaza na vektor izlaza:

$$\mathbf{y} = W\mathbf{x} + \mathbf{b}, \quad (23)$$

gdje je $\mathbf{x} \in \mathbb{R}^{d_{in}}$, $\mathbf{y} \in \mathbb{R}^{d_{out}}$, $W \in \mathbb{R}^{d_{out} \times d_{in}}$ i $\mathbf{b} \in \mathbb{R}^{d_{out}}$. Može se zamisliti kao lista koeficijenata, gdje se svaki koeficijent posebno množi sa svakom vrijednosti vektora na ulazu. Stoga, potpuno povezani sloj "vidi" globalne interakcije.

Aktivacijska funkcija uvodi nelinearnost u arhitekturu. Bez nje bi cijela mreža ostala linearna kompozicija i ne bi mogla modelirati složene odnose. Često se primjenjuje nakon linearnih slojeva. Primjeri su $\text{ReLU}(x) = \max(0, x)$ i $\tanh(x)$

Konvolucija S je skalarni produkt jednog tenzora K (npr. vektor) s obzirom na posmaknuti drugi tenzor I . U strojnom učenju

se za konvoluciju najčešće misli na unakrsnu korelaciju i u diskretnom 2D slučaju glasi:

$$\begin{aligned} S(i, j) &= (K \star I)(i, j) \\ &= \sum_{m=m_{\min}}^{m_{\max}} \sum_{n=n_{\min}}^{n_{\max}} K(m, n) I(i + m, j + n) \end{aligned} \quad (24)$$

Stoga, konvolucijski sloj "vidi" lokalne interakcije.

Unatražna propagacija (backpropagation) je postupak izračuna gradijenata funkcije gubitka $L(\theta)$ po parametrima modela θ , kako bi se minimiziralo odstupanje predikcija od stvarnih vrijednosti (L može biti npr. MSE ili MAE). Budući da je izlaz mreže kompozicija funkcija slojeva, gradijenti se računaju lančanim pravilom. Parametri se zatim ažuriraju:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L, \quad (25)$$

gdje je η stopa učenja (*learning rate*). Inače kada imamo skup podataka, dio podataka koristimo za učenje modela, a drugi dio podataka koristimo za testiranje modela. Na taj način testiranje nam govori koliko je model dobar na podacima koje nije vidio i to je prava mjera uspješnosti modela.

Literatura

- [1] D. Horvatic and D. Baric, "Dcits – deep convolutional interpreter for time series." <https://arxiv.org/abs/2501.04339>, 2025.

- [2] P. S. Cowpertwait and A. V. Metcalfe, *Introductory time series with R*. Springer Science & Business Media, 2009.
- [3] S.-A. Chen, C.-L. Li, S. O. Arik, N. C. Yoder, and T. Pfister, “TSMixer: An all-MLP architecture for time series forecast-ing,” *Transactions on Machine Learning Research*, 2023.
- [4] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems* (I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, eds.), vol. 30, Curran Associates, Inc., 2017.
- [5] U. Schlegel, D. Oelke, D. A. Keim, and M. El-Assady, “An empirical study of explainable ai techniques on deep learning models for time series tasks.” <https://arxiv.org/abs/2012.04344>, 2020.
- [6] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need.” <https://arxiv.org/abs/1706.03762>, 2017.
- [7] S. Jain and B. C. Wallace, “Attention is not explanation.” <https://arxiv.org/abs/1902.10186>, 2019.
- [8] B. N. Oreshkin, D. Carпов, N. Chapados, and Y. Bengio, “N-beats: Neural basis expansion analysis for interpretable time series forecasting.” <https://arxiv.org/abs/1905.10437>, 2020.
- [9] D. Barić and D. Horvatić, “dcits.” GitHub repository <https://github.com/hc-xai/dcits>, 2024. Maintained by the authors. Accessed: January 6, 2025.
- [10] D. Barić, P. Fumić, D. Horvatić, and T. Lipic, “Benchmarking attention-based interpretability of deep learning in multivariate time series predictions,” *Entropy*, vol. 23, no. 2, 2021. Dostupno na: <https://www.mdpi.com/1099-4300/23/2/143>.
- [11] B. Pavlović, “Određivanje dinamike fizikalnog sustava pomoću interpretabilnih algoritama dubokog učenja,” diplomski rad, Sveučilište u Zagrebu, Prirodoslovno-matematički fakultet, Fizički odsjek, Zagreb, 2025. Voditelj: prof. dr. sc. Davor Horvatić, Dostupno na: <https://repozitorij.pmf.unizg.hr/object/pmf%3A13975>.
- [12] E. Izhikevich, “Simple model of spiking neurons,” *IEEE Transactions on Neural Networks*, vol. 14, no. 6, pp. 1569–1572, 2003.
- [13] M. Stimberg, R. Brette, and D. F. Goodman, “Brian 2, an intuitive and efficient neural simulator,” *eLife*, vol. 8, p. e47314, aug 2019.
- [14] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.